



中山大學

SUN YAT-SEN UNIVERSITY

# VLM 模型：基于 Qwen2.5-VL 的微调 与评测

图文科学问答大模型

姓 名     娄康宁 刘佳鑫 马志勇    

学 号     23336166 23336151 23336183    

学 院     计算机学院    

专 业     计算机科学与技术    

2026 年 5 月 2 日

# 目录

|          |                          |          |
|----------|--------------------------|----------|
| <b>1</b> | <b>任务定义与应用背景</b>         | <b>1</b> |
| 1.1      | 任务定义 . . . . .           | 1        |
| 1.2      | 应用背景与需求 . . . . .        | 1        |
| 1.3      | 研究目标 . . . . .           | 1        |
| <b>2</b> | <b>相关工作调研</b>            | <b>1</b> |
| <b>3</b> | <b>研究目标与拟解决关键问题</b>      | <b>1</b> |
| 3.1      | 拟解决关键问题 . . . . .        | 1        |
| 3.2      | 关键技术挑战 . . . . .         | 2        |
| 3.3      | 创新点 . . . . .            | 2        |
| <b>4</b> | <b>系统方案设计</b>            | <b>3</b> |
| 4.1      | 整体架构 . . . . .           | 3        |
| 4.2      | 模型选择与理由 . . . . .        | 3        |
| 4.3      | 评测指标 . . . . .           | 4        |
| <b>5</b> | <b>初步数据集与实验设想</b>        | <b>5</b> |
| 5.1      | 数据集详情 . . . . .          | 5        |
| 5.2      | 算力预算 . . . . .           | 5        |
| 5.3      | 时间计划（第 9-16 周） . . . . . | 6        |
| 5.4      | 预期成果与风险分析 . . . . .      | 6        |
| <b>6</b> | <b>总结与展望</b>             | <b>7</b> |

## 1 任务定义与应用背景

### 1.1 任务定义

本课题旨在构建一个**图文类科学知识问答大语言模型**。形式化地，对于用户给定的图片化信息（自然场景、文档/幻灯片等），进行处理，模型需输出答案，要求准确、专业、符合科学事实与学科规范。该任务对模型的细粒度视觉感知、符号推理、数理逻辑、语言生成能力提出挑战，不同于通用视觉问答，更强调回答的**可解释性**（如给出推导步骤）和**领域一致性**（遵循物理、化学等定律）。

### 1.2 应用背景与需求

科学知识问答在教育、科研、工业场景中具有重要价值：

- **智能教育**：自动解答科学题目，辅助学生理解概念，提供个性化学习支持；
- **图表辅助**：解读实验图表，快速获取数据趋势与结论；
- **实验指导**：根据装置图回答操作规范、安全事项等问题。

### 1.3 研究目标

本研究拟达成以下目标：

1. 构建基于 Qwen2.5-VL 7B 的科学问答微调系统，实现图文输入到专业答案的端到端生成；
2. 在 ScienceQA 和 MathVista 两个必选数据集上，通过 LoRA/QLoRA 微调使准确率分别达到 92% 和 58% 以上（较零样本提升 3% 和 8%）；
3. 提供轻量级 Web 演示界面，并评测推理延迟与显存占用等工程指标。

## 2 相关工作调研

本领域代表性工作包括参数高效微调方法、多模态科学问答基准以及基础模型。表 1 总结了关键文献的核心贡献。

这些工作为本研究提供了方法基础、评测标准和模型底座。

## 3 研究目标与拟解决关键问题

### 3.1 拟解决关键问题

1. **科学图表中的精细视觉理解**：如何有效提取微小文字、数据点、图表结构等细节？

表 1: 代表性相关工作对比

| 类型      | 文献             | 核心贡献                         |
|---------|----------------|------------------------------|
| 参数高效微调  | LoRA [1]       | 低秩分解更新矩阵，可训练参数降低至 0.01%      |
| 参数高效微调  | QLoRA [2]      | 4-bit 量化 + 双重量化，单卡可微调 65B 模型 |
| 大模型推理   | LLM.int8() [3] | 向量级量化解决异常值，保障 8-bit 推理精度     |
| 科学问答基准  | ChartQA [4]    | 2.2 万图表，数值推理和比较的标注           |
| 科学问答基准  | MathVista [5]  | 7 类数学任务，6141 个视觉上下文样本        |
| 多模态基础模型 | Qwen2-VL [6]   | 动态分辨率，2D-RoPE，10+ 基准 SOTA    |
| 综述      | 综述 [7]         | 多模态大模型架构、训练、评估全面总结           |

2. **符号化推理与语言生成的结合**：如何在生成答案时嵌入计算步骤或逻辑推导，而不直接输出结论？
3. **低资源高效微调**：在有限算力下（单卡 A100 40G），如何平衡模型性能与训练成本？

### 3.2 关键技术挑战

- **多模态对齐**：科学图像中的符号（如数学公式、化学式）与文本描述之间可能存在歧义，需要更精确的对齐。
- **长文本推理**：部分科学题目需要多步推理（如几何证明），而模型上下文窗口有限，需设计合适的链式思考提示。
- **数据不平衡**：MathVista 中代数题型占比较高，几何题型相对较少，可能导致模型泛化偏差。

### 3.3 创新点

- 针对 Qwen2.5-VL 在科学问答任务上进行系统性的 LoRA/QLoRA 适配，并对比两种策略的权衡；
- 提出一种基于指令模板多样性的数据增强方法，提升模型对提问方式的鲁棒性；

- 设计“客观准确率 + 主观人工评分 + 性能指标”三维评估体系，兼顾科学性、可解释性与工程实用性。

## 4 系统方案设计

### 4.1 整体架构

系统采用三层解耦架构，如图 1 所示。

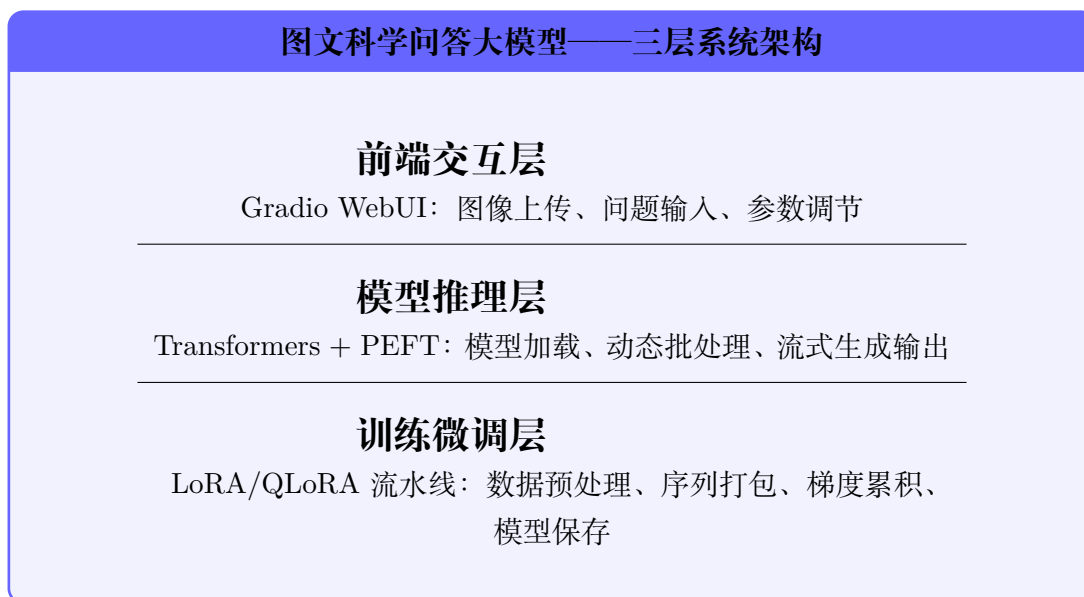


图 1: 系统整体架构示意图

- **前端**: 基于 Gradio 实现交互界面，支持拖拽图片、实时调节温度系数和 top-p，并展示模型回答和推理耗时。
- **推理层**: 使用 HuggingFace Transformers 加载 Qwen2.5-VL 7B Instruct，支持 int8/bf16 两种精度，并实现动态批处理（dynamic batching）以提高吞吐量。集成 FlashAttention-2 优化注意力计算。
- **微调层**: 采用 PEFT 库实现 LoRA，目标模块为注意力层的 q\_proj 和 v\_proj，超参数如表 2 所示。支持 DeepSpeed ZeRO-2 多卡训练，并提供模型版本管理。

### 4.2 模型选择与理由

采用 Qwen2.5-VL 7B Instruct，理由如下：

- **视觉能力**: 原生支持任意分辨率，使用 ViT 架构和 2D-RoPE 位置编码，对图表中的微小文字、坐标轴标签识别能力强；

表 2: LoRA 微调核心超参数配置

| 参数                      | 值                  | 说明                               |
|-------------------------|--------------------|----------------------------------|
| LoRA rank ( $r$ )       | 16                 | 平衡参数量与表达能力                       |
| LoRA alpha ( $\alpha$ ) | 32                 | 缩放因子                             |
| 目标模块                    | q_proj, v_proj     | 仅微调注意力层                          |
| 学习率                     | $2 \times 10^{-4}$ | 余弦退火调度, warmup ratio=0.03        |
| 全局批次大小                  | 16                 | 每卡 batch=8, 梯度累积 2 步             |
| 训练轮数                    | 3                  | 早停轮数 1 (基于验证 EM)                 |
| 最大序列长度                  | 1024               | 文本 + 图像 token 总数                 |
| 优化器                     | AdamW              | $\beta_1 = 0.9, \beta_2 = 0.999$ |
| 混合精度                    | bf16               | 梯度检查点启用                          |

- **科学推理基础**: 官方报告在 ScienceQA 零样本 EM 为 89.5%, MathVista 零样本为 50.2%, 具备良好起点;
- **计算友好**: 7B 参数量适配单卡 A100 40G, 推理和微调成本可控, 社区活跃, 文档丰富。

作为对比, 我们还将测试 LLaVA-v1.6-7B 和 BLIP-2 在该任务上的表现。

### 4.3 评测指标

采用三维评估体系:

#### 1. 客观准确率:

- 多项选择题: Exact Match (EM);
- 开放生成题: ROUGE-L、BLEU-4, 以及数值问题相对误差  $\leq 5\%$  即视为正确。

#### 2. 主观人工评分:

邀请 5 名理工科研究生, 对 200 条随机抽样回答从三个维度 (专业性、完整性、可解释性) 按 1-5 分打分, 最终取平均。使用 Fleiss' Kappa 检验评分一致性。

#### 3. 性能指标:

平均延迟 (ms/样本)、显存峰值 (GB)、吞吐量 (samples/s), 记录在不同精度 (int8 / bf16) 和批处理大小下的表现。

## 5 初步数据集与实验设想

### 5.1 数据集详情

必选数据集及划分如下（可选数据集如 VQAv2, ChartQA 用于泛化性测试，不参与微调）：

表 3: 必选数据集统计与划分

| 数据集       | 训练集    | 验证集   | 测试集   | 问题类型       | 图像来源       |
|-----------|--------|-------|-------|------------|------------|
| ScienceQA | 12,000 | 1,000 | 2,000 | 多项选择（4 选项） | 教科书、示意图    |
| MathVista | 4,000  | 1,000 | 1,141 | 多选/数值/开放   | 图表、几何图、场景图 |

数据预处理流程：

1. 图像统一调整短边至 448 像素，保持长宽比，不足部分填充黑色；
2. 随机数据增强：亮度抖动（ $\pm 20\%$ ）、对比度增强（ $\pm 15\%$ ）、水平翻转（概率 0.5）；
3. 文本构建指令模板：为每个样本随机选择 3 种模板之一（如“请根据图片回答问题：{question}”或“观察图像，回答：{question}”），提升鲁棒性。

### 5.2 算力预算

实验环境：GPU 环境：8 核 32GB 显存 24G

**GPU环境** ⓘ

8核 32GB 显存24G（更高阶卡型需求，可使用[个人云账号授权实例](#)）

预装 ModelScope Library

预装镜像 `ubuntu22.04-cuda12.8.1-py311-torch2.9.1-1.35.0`

- 模型加载显存：int8 约 8GB，bf16 约 14GB。
- LoRA + bf16 训练：显存约 18GB，全局 batch=16（每卡 8，梯度累积 2）。预计训练时间：ScienceQA 3 轮约 12 小时，MathVista 3 轮约 8 小时。
- QLoRA + 4-bit 训练：显存约 12GB，全局 batch 可增至 24，训练速度提升 20%，但可能存在 1% 左右的精度损失。

- 评测时间：测试集总计约 4000 样本，批处理 8 时约需 6 小时。

### 5.3 时间计划（第 9-16 周）

详细周计划如表 4 所示。

表 4: 项目时间计划表（周次）

| 周次        | 主要工作内容                                     |
|-----------|--------------------------------------------|
| 第 10 周    | 环境配置，数据集下载，编写数据加载与预处理脚本。                   |
| 第 11 周    | 跑通 baseline，并完成 Gradio 前端。                 |
| 第 12 周    | 实现 LoRA 微调脚本，在 ScienceQA 上面进行微调。           |
| 第 13 周    | 尝试联合训练（ScienceQA、MathVista 等），对比单任务与多任务效果。 |
| 第 14、15 周 | 微调模型挂到 Gradio 测试，记录典型案例和显存/耗时，并进行结果，优化推理。  |
| 第 16 周    | 完成最终实验报告，整理代码与适配器权重，准备项目展示。                |

### 5.4 预期成果与风险分析

**预期成果：**

- 可工作的科学问答 Web 演示系统（公开 Gradio 链接）；
- ScienceQA 测试集 EM  $\geq 92\%$ ，MathVista 测试集 EM  $\geq 58\%$ ，均优于零样本基线；
- 提供 LoRA 与 QLoRA 的显存-精度 trade-off 曲线报告；
- 开源代码（GitHub）及微调后的 LoRA 适配器权重。

**风险与对策：**

- 数据格式异常：ScienceQA 部分样本缺失图像，需编写容错脚本，过滤无效样本。
- MathVista 几何图低分辨率：使用 Real-ESRGAN 超分辨率预处理，提升视觉细节。
- 人工评分一致性差：提前制定详细评分细则，进行小规模预评分并校准，最终计算 Kappa 系数衡量一致性。
- 显存溢出：采用梯度检查点、混合精度、QLoRA 逐步降级方案。



## 6 总结与展望

本开题报告明确了图文科学问答的任务定义、应用背景，调研了 7 篇代表性工作，设计了基于 Qwen2.5-VL 的三层架构系统，并给出了详尽的微调实验计划。后续将按计划推进，确保第 16 周前完成所有实验与报告撰写。XZ

## 参考文献

- [1] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[J]. arXiv preprint arXiv:2106.09685, 2021.
- [2] Dettmers T, Pagnoni A, Holtzman A, et al. QLoRA: Efficient Finetuning of Quantized LLMs[J]. arXiv preprint arXiv:2305.14314, 2023.
- [3] Dettmers T, Lewis M, Belkada Y, et al. LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale[J]. arXiv preprint arXiv:2208.07339, 2022.
- [4] Masry A, Long D, Tan J Q, et al. ChartQA: A Benchmark for Question Answering about Charts with Visual and Logical Reasoning[J]. arXiv preprint arXiv:2203.10244, 2022.
- [5] Lu P, Bansal H, Xia T, et al. MathVista: Evaluating Mathematical Reasoning of Foundation Models in Visual Contexts[J]. arXiv preprint arXiv:2310.02255, 2023.
- [6] Wang P, Yang A, Men R, et al. Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution[J]. arXiv preprint arXiv:2402.11681, 2024.
- [7] Yin S, Fu C, Zhao S, et al. A Survey on Multimodal Large Language Models[J]. arXiv preprint arXiv:2306.13549, 2023.